

ρ = Bytes per Parameter (B/N)

Model Size (N)

143M

292

569

899

1.1k

1.2k

1.3k

262M

117

242

418

532

612

716

340M

76

160

287

375

439

526

432M

48

99

175

228

266

317

540M

33

69

125

166

197

240

664M

23

49

91

122

147

182

805M

16

35

66

90

110

139

966M

11

22

40

53

64

78

1.3B

6.0

13

24

32

39

49

1.8B

3.5

7.2

14

19

23

29

2.4B

2.1

4.4

8.5

12

15

19

1

2

4

6

8

12

Compression Rate (T)

200B

100B

50B

20B

10B

Data in Bytes (B)